

GZHV2 商业研究中台升级技术文档

1. 项目目标

将 GZHV2 从 “AI 公司信息卡片生成器” 升级为 “可追溯、可复用、可扩展的商业研究中台”。

核心目标：

1. 输入公司名或官网后，自动完成公司识别、信息采集、证据抽取、字段解析、缺口判断、补采、定稿和卡片生成。
2. 8 页知识卡片不再依赖固定宽表，而是由字段池和卡片配置动态组合。
3. 每个字段必须能回答三个问题：
 4. 值从哪里来；
 5. 是否可信；
 6. 为什么最终采用这个版本。
7. 对不可公开获得的指标，例如 CAC、LTV、毛利率、Burn Rate，不再强行补搜或硬填，而是按规则标记为不可得、代理估算或行业均值。
8. 借鉴 BettaFish 的多 Agent 分工和论坛式校验机制，但改造为适合 AI 初创公司商业研究的字段驱动流程。

2. 当前问题判断

2.1 数据库层问题

当前字段设计把四类内容混在一起：

1. 原始事实字段；
2. 多模型候选结果；
3. 人工定稿结果；
4. 卡片展示文案。

典型表现：

字段 Key / 标签 / Standard / Business / Spread / 定稿值 / 状态

这种结构适合人工对比，不适合系统长期维护。

核心问题是：字段没有证据绑定，多版本结果没有独立候选记录，定稿值和原始事实没有分层。

2.2 研究流程问题

当前链路大致是：

公司识别

- Tavily / GitHub / YouTube / 官网并行采集
- evidence_pool 去重打分
- gap_detector 缺口补采
- L0-L3 LLM 分析
- research 宽表
- research_fields 字段拆分
- final_fields 定稿
- 卡片渲染

已有基础是好的，但存在 5 个关键缺陷：

1. 证据池没有真正成为字段确认依据。
2. L0 输入会清理 `_evidence_pool`、`_source_summary` 等内部字段，导致证据层半失效。
3. `confirmed` 状态过宽松，只要 LLM 有值就可能被认为已确认。
4. 缺口补采没有严格遵守字段可得性规则，私有指标也会被反复搜索。
5. `company_key` 没有贯穿字段层和定稿层，容易出现 `Limitless / limitless / limitless.ai` 分裂。

3. 总体设计原则

3.1 字段不是卡片

数据库不应该按 8 页卡片直接建宽表。

正确关系是：

事实字段池

- 分析字段池
- 定稿字段池
- 卡片配置
- HTML / PNG / Markdown 渲染

卡片只是展示方案，不是底层数据结构。

3.2 事实、推理、文案必须分层

类型	示例	存储位置
事实	成立时间、融资金额、官网、客户名称	companies / products / funding_rounds / customers / metrics
指标	ARR、MAU、留存率、LTV/CAC	metrics
证据	来源网页、引用片段、截图、访谈字幕	source_documents / evidence_spans
推理	生态位、竞争优势、错位机会	company_analysis

类型	示例	存储位置
候选答案	Standard / Business / Spread	field_candidates
定稿文案	卡片最终显示内容	final_card_values

3.3 所有字段必须有状态

统一状态枚举：

confirmed	有直接证据确认
derived	由已确认字段计算得出
proxy	基于同类公司或市场报告估算
industry_avg	使用行业平均值
llm_extracted	LLM 提取但未绑定证据
manual_needed	需要人工判断
unavailable	公开不可得
not_applicable	不适用
conflict	多来源冲突
draft	待定稿
hidden	不展示

禁止继续只用：

暂缺
未知
—

4. 目标系统架构

升级后的研究流程：

```

输入公司名 / 官网
↓
CompanyIdentityAgent
公司身份归一化, 生成 company_key
↓
SourcePlanningAgent
根据字段需求生成采集计划
↓
多 Agent 并行采集
OfficialAgent / QueryAgent / MediaAgent / CommunityAgent / GitHubAgent / InsightAgent
↓

```

source_documents
保存完整来源文档
↓
EvidenceExtractor
从文档中切出字段证据片段
↓
evidence_spans
证据片段入库
↓
FieldResolver
字段确认、估算、不可得、冲突处理
↓
ForumModerator
检查字段冲突、幻觉、证据不足
↓
GapRefetchPlanner
只对可补采字段执行二次补采
↓
AnalysisResolver
生成生态位、GTM、竞争态势、变现能力等分析字段
↓
ReportAgent
生成 Standard / Business / Spread 候选版本
↓
final_card_values
人工或自动定稿
↓
card_schema
自由组合为 8 页知识卡片
↓
HTML / PNG / Markdown 输出

5. 数据库设计

5.1 公司主体表: **companies**

```
CREATE TABLE companies (  
  id TEXT PRIMARY KEY,  
  company_key TEXT NOT NULL UNIQUE,  
  name TEXT NOT NULL,  
  canonical_name TEXT,  
  aliases TEXT,  
  website_url TEXT,  
  company_category TEXT,  
  company_definition TEXT,  
  founded_date TEXT,  
  hq_country TEXT,  
  hq_city TEXT,
```

```
main_business TEXT,
core_advantage TEXT,
industry_positioning TEXT,
data_confidence TEXT DEFAULT 'medium',
created_at TEXT DEFAULT CURRENT_TIMESTAMP,
updated_at TEXT DEFAULT CURRENT_TIMESTAMP
);
```

说明：

- `company_key` 是主身份，建议使用官网 host，例如 `sardine.ai`。
- `name` 只是展示名，不再作为主键。
- 所有表优先关联 `company_key`。

5.2 产品表： `products`

```
CREATE TABLE products (
  id TEXT PRIMARY KEY,
  company_key TEXT NOT NULL,
  name TEXT NOT NULL,
  is_primary INTEGER DEFAULT 0,
  product_definition TEXT,
  target_pain_points TEXT,
  core_features TEXT,
  usage_play TEXT,
  tech_stack TEXT,
  regional_markets TEXT,
  pricing_detail TEXT,
  product_url TEXT,
  screenshot_asset_id TEXT,
  confidence TEXT DEFAULT 'medium',
  created_at TEXT DEFAULT CURRENT_TIMESTAMP
);
```

第三页主产品字段从这里读取：

名称
 针对的痛点
 核心功能
 核心用法玩法
 技术栈
 地区市场
 定价明细

月活、留存率等指标不放在 `products`，统一放入 `metrics`。

5.3 指标表: `metrics`

```
CREATE TABLE metrics (  
  id TEXT PRIMARY KEY,  
  company_key TEXT NOT NULL,  
  entity_type TEXT NOT NULL,  
  entity_id TEXT,  
  metric_key TEXT NOT NULL,  
  metric_value REAL,  
  metric_text TEXT,  
  unit TEXT,  
  period TEXT,  
  region TEXT,  
  segment TEXT,  
  source_id TEXT,  
  status TEXT DEFAULT 'unavailable',  
  estimate_method TEXT,  
  confidence TEXT DEFAULT 'medium',  
  created_at TEXT DEFAULT CURRENT_TIMESTAMP  
);
```

适合放入 `metrics` 的字段:

```
market_size  
market_cagr  
tam  
sam  
som  
arr  
mrr  
mau  
active_users  
registered_users  
paying_users  
retention_rate  
churn_rate  
ltv  
cac  
ltv_cac_ratio  
gross_margin  
burn_rate  
runway_months  
team_size
```

5.4 赛道表: `sectors`

```
CREATE TABLE sectors (  
  id TEXT PRIMARY KEY,  
  company_key TEXT NOT NULL,  
  sector_name TEXT,  
  market_landscape TEXT,  
  market_size_summary TEXT,  
  market_cagr_summary TEXT,  
  tam_summary TEXT,  
  source_note TEXT,  
  confidence TEXT DEFAULT 'medium'  
);
```

说明:

- `sectors` 存文本判断;
- 具体数字仍进入 `metrics`;
- 市场规模必须包含口径: 年份、地区、细分赛道、数据来源。

5.5 创始团队表: `founders`

```
CREATE TABLE founders (  
  id TEXT PRIMARY KEY,  
  company_key TEXT NOT NULL,  
  name TEXT NOT NULL,  
  role TEXT,  
  education TEXT,  
  career_background TEXT,  
  founder_achievement TEXT,  
  credibility_note TEXT,  
  linkedin_url TEXT,  
  confidence TEXT DEFAULT 'medium'  
);
```

新增 `credibility_note`, 用于解释:

为什么这个团队适合做这家公司?

这是创始团队页最重要的判断。

5.6 融资表: `funding_rounds`

```
CREATE TABLE funding_rounds (  
  id TEXT PRIMARY KEY,
```

```
company_key TEXT NOT NULL,  
round_name TEXT,  
announced_date TEXT,  
amount_usd REAL,  
valuation_usd REAL,  
lead_investor TEXT,  
investors TEXT,  
source_id TEXT,  
confidence TEXT DEFAULT 'medium'  
);
```

第二页“融资情况”由这张表聚合生成，不再手写长文本。

5.7 客户与用户群体表: `customers`

```
CREATE TABLE customers (  
id TEXT PRIMARY KEY,  
company_key TEXT NOT NULL,  
customer_type TEXT,  
persona_name TEXT,  
customer_name TEXT,  
industry TEXT,  
customer_pain TEXT,  
choice_reason TEXT,  
evidence_summary TEXT,  
source_id TEXT,  
confidence TEXT DEFAULT 'medium'  
);
```

`customer_type` 可选:

```
persona  
named_customer  
industry_segment
```

第五页字段映射:

```
用户画像 → customer_type = persona  
具体客户名称 → customer_type = named_customer  
客户选择理由 → choice_reason + evidence_summary
```


5.8 竞品表: `competitors`

```
CREATE TABLE competitors (  
  id TEXT PRIMARY KEY,  
  company_key TEXT NOT NULL,  
  competitor_name TEXT NOT NULL,  
  competitor_url TEXT,  
  product_summary TEXT,  
  company_summary TEXT,  
  rank INTEGER,  
  overlap_area TEXT,  
  difference_area TEXT,  
  competitor_strength TEXT,  
  competitor_weakness TEXT,  
  source_id TEXT,  
  confidence TEXT DEFAULT 'medium'  
);
```

第八页字段映射:

Top3 公司简介 → competitors
被研公司在竞争中的位置 → company_analysis.competitive_position
错位竞争机会 → company_analysis.differentiation_opportunity
竞争优势 → company_analysis.competitive_advantage

5.9 公司分析表: `company_analysis`

```
CREATE TABLE company_analysis (  
  id TEXT PRIMARY KEY,  
  company_key TEXT NOT NULL,  
  ecosystem_niche TEXT,  
  monetization_strategy TEXT,  
  pricing_strategy TEXT,  
  value_capture_score REAL,  
  defensibility_score REAL,  
  competitive_position TEXT,  
  differentiation_opportunity TEXT,  
  competitive_advantage TEXT,  
  moat TEXT,  
  risk_window TEXT,  
  gtm_motion TEXT,  
  cold_start TEXT,  
  growth_strategy TEXT,  
  growth_flywheel TEXT,  
  analysis_version INTEGER DEFAULT 1,  
  confidence TEXT DEFAULT 'medium',
```

```
created_at TEXT DEFAULT CURRENT_TIMESTAMP
);
```

说明：

- 这里存推理结果；
- 不存原始事实；
- 所有分析必须尽量引用 `evidence_spans` 或 `confirmed` 字段。

5.10 来源文档表： `source_documents`

```
CREATE TABLE source_documents (
  id INTEGER PRIMARY KEY AUTOINCREMENT,
  run_id TEXT,
  company_key TEXT,
  source_type TEXT,
  source_url TEXT,
  title TEXT,
  publisher TEXT,
  published_at TEXT,
  fetched_at TEXT DEFAULT CURRENT_TIMESTAMP,
  raw_text TEXT,
  content_hash TEXT,
  trust_tier TEXT,
  intent TEXT
);
```

`source_type` 可选：

```
official_site
official_blog
pricing_page
case_study
press_release
media_article
github
youtube
youtube_transcript
product_hunt
hacker_news
reddit
market_report
database
manual
```

5.11 证据片段表: `evidence_spans`

```
CREATE TABLE evidence_spans (  
  id INTEGER PRIMARY KEY AUTOINCREMENT,  
  document_id INTEGER NOT NULL,  
  company_key TEXT NOT NULL,  
  field_key TEXT,  
  quote_text TEXT,  
  normalized_fact TEXT,  
  start_offset INTEGER,  
  end_offset INTEGER,  
  confidence REAL,  
  created_by_agent TEXT,  
  created_at TEXT DEFAULT CURRENT_TIMESTAMP  
);
```

这张表解决字段可追溯问题。

5.12 研究运行表: `research_runs`

```
CREATE TABLE research_runs (  
  id TEXT PRIMARY KEY,  
  company_key TEXT NOT NULL,  
  display_name TEXT,  
  input_query TEXT,  
  research_depth TEXT,  
  status TEXT,  
  started_at TEXT DEFAULT CURRENT_TIMESTAMP,  
  finished_at TEXT,  
  config_json TEXT  
);
```

5.13 候选字段表: `field_candidates`

```
CREATE TABLE field_candidates (  
  id INTEGER PRIMARY KEY AUTOINCREMENT,  
  run_id TEXT NOT NULL,  
  company_key TEXT NOT NULL,  
  field_key TEXT NOT NULL,  
  agent_name TEXT,  
  candidate_value TEXT,  
  evidence_span_ids TEXT,  
  confidence REAL,  
  status TEXT,  
  conflict_group_id TEXT,  
  reasoning_summary TEXT,
```

```
selected INTEGER DEFAULT 0,  
created_at TEXT DEFAULT CURRENT_TIMESTAMP  
);
```

用于替代当前混在一起的：

Standard / Business / Spread

5.14 字段定稿表： `final_card_values`

```
CREATE TABLE final_card_values (  
  id INTEGER PRIMARY KEY AUTOINCREMENT,  
  run_id TEXT NOT NULL,  
  company_key TEXT NOT NULL,  
  card_no INTEGER NOT NULL,  
  field_key TEXT NOT NULL,  
  final_value TEXT,  
  source_evidence_ids TEXT,  
  status TEXT DEFAULT 'draft',  
  confidence TEXT DEFAULT 'medium',  
  editor_note TEXT,  
  updated_at TEXT DEFAULT CURRENT_TIMESTAMP,  
  UNIQUE(company_key, card_no, field_key)  
);
```

5.15 卡片配置表： `card_schema`

```
CREATE TABLE card_schema (  
  id INTEGER PRIMARY KEY AUTOINCREMENT,  
  card_no INTEGER NOT NULL,  
  card_title TEXT NOT NULL,  
  field_key TEXT NOT NULL,  
  display_label TEXT,  
  render_order INTEGER,  
  required INTEGER DEFAULT 0,  
  max_length INTEGER,  
  render_type TEXT DEFAULT 'text'  
);
```

8 页卡片不再写死在代码里，而是由 `card_schema` 控制。

6.8 页卡片字段映射

第 1 页：首页

company_name	→ companies.name
company_category	→ companies.company_category

第 2 页：公司简介

赛道市场格局	→ sectors.market_landscape
赛道市场规模	→ metrics.metric_key = market_size
赛道年复合增长率	→ metrics.metric_key = market_cagr
赛道总潜在市场	→ metrics.metric_key = tam
公司地理位置	→ companies.hq_city + companies.hq_country
公司成立时间	→ companies.founded_date
公司主营业务	→ companies.main_business
公司核心竞争优势	→ companies.core_advantage
公司融资情况	→ funding_rounds 聚合
公司取得成就	→ company_analysis 或 evidence 聚合
公司行业定位	→ companies.industry_positioning

第 3 页：主产品

名称	→ products.name where is_primary = 1
针对的痛点	→ products.target_pain_points
核心功能	→ products.core_features
核心用法玩法	→ products.usage_play
技术栈	→ products.tech_stack
地区市场	→ products.regional_markets
月活跃用户	→ metrics.metric_key = mau
留存率	→ metrics.metric_key = retention_rate
定价明细	→ products.pricing_detail

第 4 页：创始团队

创始人姓名	→ founders.name
职位	→ founders.role
学历背景	→ founders.education
职业背景	→ founders.career_background
关键成就	→ founders.founder_achievement

团队亮点	→ founders.credibility_note 或 company_analysis
团队规模	→ metrics.metric_key = team_size

第 5 页：用户群体

用户画像	→ customers.customer_type = persona
具体客户名称	→ customers.customer_type = named_customer
客户选择理由	→ customers.choice_reason
数据与事实支撑	→ customers.evidence_summary + evidence_spans

第 6 页：公司能力分析

生态位分析	→ company_analysis.ecosystem_niche
盈利策略	→ company_analysis.monetization_strategy
定价策略	→ company_analysis.pricing_strategy
LTV	→ metrics.metric_key = ltv
CAC	→ metrics.metric_key = cac
LTV/CAC	→ metrics.metric_key = ltv_cac_ratio

LTV/CAC 显示规则：

公司披露	→ confirmed
同类公司推断	→ proxy
行业均值	→ industry_avg
没有依据	→ unavailable

卡片文案必须显式标注：

“行业平均，不代表公司披露”

第 7 页：增长与 GTM

冷启动策略	→ company_analysis.cold_start
GTM 打法	→ company_analysis.gtm_motion
增长策略	→ company_analysis.growth_strategy
增长飞轮	→ company_analysis.growth_flywheel
渠道结构	→ company_analysis 或 metrics

GTM 是 Go-To-Market，指产品如何触达客户、转化客户并形成销售闭环。
B2B 公司重点看直销、渠道、合作伙伴、创始人网络、标杆客户和 PoC。

第 8 页：竞争态势

Top3 公司简介	→ competitors
被研公司竞争位置	→ company_analysis.competitive_position
错位竞争机会	→ company_analysis.differentiation_opportunity
竞争优势	→ company_analysis.competitive_advantage

7. 信息采集方法设计

7.1 字段驱动采集

当前做法偏向：

公司名 → 搜索 query → LLM 总结

目标做法：

字段需求 → 来源策略 → 采集任务 → 文档入库 → 证据片段 → 字段解析

示例：

```
funding_info:
  preferred_sources:
    - official_press
    - techcrunch
    - crunchbase
    - pitchbook
  query_templates:
    - "{company}" funding round valuation investors'
    - "{company}" raised Series A OR Series B OR Series C'
  confirm_rule:
    min_evidence: 1
    allowed_tiers:
      - official
      - trusted_media
      - financial_database

ltv_cac_ratio:
  preferred_sources:
    - company_financials
    - founder_interview
    - latka
    - sacra
  fallback:
```

```
- industry_benchmark
confirm_rule:
  never_confirm_without_direct_number: true
```

7.2 OfficialAgent：官网深爬

当前官网只抓首页，不足。
新增 `official_agent.py`，按站内路径抓取：

```
/
/about
/company
/team
/founders
/pricing
/customers
/case-studies
/blog
/news
/press
/docs
/changelog
/security
/careers
```

字段映射：

页面	可支撑字段
About	公司定义、地点、成立时间、主营业务
Team	创始人、团队亮点
Pricing	定价明细、定价策略
Customers	客户名称、用户群体
Case Studies	客户痛点、选择理由、ROI
Blog / News	产品发布、时间线、公司成就
Docs	技术栈、集成方式、API
Careers	团队规模、技术栈、地区扩张

7.3 QueryAgent：公开网页搜索

负责：

融资
市场规模
竞品
公司成就
行业定位
公开指标
新闻事件

搜索不应再追求盲目增多，而应按字段分配 query budget。

优先级：

A 类字段：必须补采
C 类字段：允许补采一次
D/E 类字段：默认不补采

7.4 GitHubAgent：开源与技术信号采集

当前 GitHub 只搜 repo metadata，建议扩展为：

README
docs
releases
issues
discussions
stars
forks
contributors
last_commit_at
license
topics

支撑字段：

技术栈
开发者采用度
开源替代
产品成熟度
社区信号
技术壁垒

7.5 MediaAgent：视频与访谈采集

当前 YouTube 只取标题和描述，不足。

新增字幕提取：

```
搜索 founder interview / product demo / podcast
→ 获取 video_id
→ 抓 transcript
→ 分段
→ 提取创始人背景、GTM、产品理念、冷启动、关键指标
→ 写入 source_documents
```

支撑字段：

```
founder_bg
founder_achievement
cold_start
gtm_strategy
market_opportunity
product_pain_points
```

7.6 CommunityAgent：社区信号采集

采集对象：

```
Product Hunt
Hacker News
Reddit
G2
Capterra
Chrome Web Store
App Store
X/Twitter 搜索结果
```

支撑字段：

```
用户痛点
10分钟惊喜点
用户吐槽
替代竞品
传播钩子
真实使用场景
```

限制：

社区来源不能用于确认融资、收入、学历、团队规模等硬事实。

7.7 InsightAgent：内部样本库与行业均值

负责：

历史公司对比
行业均值
同类产品 benchmark
过往研究样本复用

用于解决：

LTV/CAC 搜不到
CAC 搜不到
留存率搜不到
行业平均缺失

但输出必须标记为：

proxy
industry_avg

不能标记为：

confirmed

8. 研究方法设计

8.1 从 L0-L3 串行改为字段解析

当前：

L0 清洗
→ L1 横纵分析
→ L2 商业结构
→ L3 字段提取

目标：

Evidence Pool
→ Field Resolver
→ Forum Review
→ Gap Refetch
→ Analysis Resolver
→ Card Writer

原因：

1. 串行 LLM 容易把早期遗漏传递到后面；
2. 字段级解析更容易绑定证据；
3. 分析字段应基于 confirmed / proxy 字段生成，而不是直接从原始搜索结果生成。

8.2 FieldResolver 规则

字段按类型处理：

字段类型	处理方式
官方事实	必须绑定证据
枚举字段	规则层 + LLM 投票 + 验证
公式字段	依赖 confirmed 字段计算
市场字段	必须有 region / segment / year
私有经营指标	默认 unavailable 或 proxy
B2B 不适配字段	转换为客户数、Logo、账户数
推理字段	基于事实字段生成，标记 analysis

8.3 ForumModerator 校验机制

借鉴 BettaFish 的论坛协作，但 GZHV2 只做字段校验，不做复杂辩论。

输入：

```
{
  "field_key": "funding_info",
  "claim": "Series C $70M, valuation $660M",
  "evidence_ids": [12, 18],
  "source_tier": "trusted_media",
  "confidence": 0.82,
  "risk": "date conflict"
}
```

ForumModerator 只做三件事：

1. 找冲突
2. 找缺口
3. 找证据不足但被标 `confirmed` 的字段

输出：

```
conflict_fields
weak_evidence_fields
refetch_tasks
manual_needed_fields
```

8.4 缺口补采规则

禁止所有缺失字段都补采。

按字段可得性分类：

- A 类：强事实字段，必须补采
- B 类：官网/产品字段，优先官网补采
- C 类：市场/竞品字段，允许补采一次
- D 类：私有经营指标，不补采，转 `unavailable` / `proxy`
- E 类：不适用字段，不补采，转 `not_applicable`

示例：

```
def should_refetch(field_key, manifest):
    category = manifest[field_key]["category"]
    return category in ["A", "B", "C"]
```

9. 代码改造方案

9.1 P0：修复 L0 输入

当前 `_prepare_raw_data_for_llm()` 会删除 `_evidence_pool`、`_source_summary`、`_source_warnings`。

目标：保留结构化证据输入。

建议改为：

```
def _prepare_raw_data_for_llm(raw_data):
    return {
```

```

"company_identity": {
    "company_key": raw_data.get("company_key"),
    "display_name": raw_data.get("display_name"),
    "website_host": raw_data.get("website_host"),
    "aliases": raw_data.get("aliases", []),
},
"source_audit": raw_data.get("_source_summary", {}),
"source_warnings": raw_data.get("_source_warnings", []),
"evidence_pool": [
    {
        "source": e.source,
        "intent": e.intent,
        "title": e.title,
        "url": e.url,
        "content": e.content[:1200],
        "metric_snippet": e.metric_snippet,
        "source_score": e.source_score,
        "entity_score": e.entity_score,
        "final_score": e.final_score,
    }
    for e in raw_data.get("_evidence_pool", [])[:80]
],
"raw_sources": {
    "tavily": raw_data.get("tavily"),
    "github": raw_data.get("github"),
    "youtube": raw_data.get("youtube"),
    "website": raw_data.get("website"),
}
}

```

验收标准：

L0 prompt 输入中可以看到 evidence_pool、source_audit、company_identity。

9.2 P0: company_key 贯穿字段层

需要修改：

```

webapp/services/field_service.py
webapp/repositories/field_repo.py
db/migrations
final_fields
research_fields

```

当前：

company_name 作为查询主键

目标：

company_key 作为查询主键
company_name 作为展示字段

迁移策略：

1. research_fields 增加 company_key ；
2. final_fields 增加 company_key ；
3. 旧数据用 company_identity 或官网 host 回填；
4. 查询优先使用 company_key ，缺失时回退 company_name 。

9.3 P0：字段状态必须绑定证据

当前 field_resolver.py 中 official_fact 、 private_metric 有值即 confirmed ，风险较大。

改造规则：

没有 evidence_span_ids → 不得 confirmed
private_metric 没有直接来源 → unavailable
market_model 没有 region / segment / year → manual_needed
derived 输入字段不是 confirmed / proxy → blocked

新增状态：

llm_extracted
industry_avg
conflict

9.4 P0：缺口补采读取 field_manifest

当前 gap_detector.py 用 CRITICAL_GAPS 判断缺口。
应改为读取 references/field_manifest.yaml 。

伪代码：

```
def build_gap_queries(display_name, website_host, root_domain, gaps, manifest):  
    queries = []  
    for intent, fields in gaps.items():  
        refetchable_fields = []
```

```

for field in fields:
    entry = manifest.get(field, {})
    if entry.get("category") in ["A", "B", "C"]:
        refetchable_fields.append(field)

if not refetchable_fields:
    continue

for tpl in GAP_QUERY_TEMPLATES.get(intent, []):2]:
    queries.append({
        "query": tpl.format(
            display_name=display_name,
            website_host=website_host,
            root_domain=root_domain
        ),
        "intent": intent,
        "fields": refetchable_fields
    })
return queries

```

验收标准：

CAC / LTV / Burn Rate / Gross Margin 不再被默认补采。

9.5 P1：新增 source_documents 和 evidence_spans

当前 `evidence_items` 还偏轻，只保存摘要级证据。

下一步应保存完整文档与证据片段。

新增模块：

```

webapp/research/document_store.py
webapp/research/evidence_extractor.py

```

流程：

```

采集结果
→ source_documents
→ evidence_extractor
→ evidence_spans
→ field_candidates

```


9.6 P1: 官网深爬

新增：

```
webapp/research_agents/agents/official_agent.py
```

职责：

```
发现站内关键路径
抓取页面
清洗正文
写 source_documents
提取 evidence_spans
```

最小实现：

```
先只爬 10 个固定路径
每页最多 5000 字
总字符上限 50000
失败不阻塞主流程
```

9.7 P1: Field Candidate 替代三版本混表

当前 `Standard / Business / Spread` 是展示版本，不是真正研究视角。

改造后：

```
OfficialAgent 候选
QueryAgent 候选
MediaAgent 候选
InsightAgent 候选
MetricAgent 候选
ReportAgent Standard 文案
ReportAgent Business 文案
ReportAgent Spread 文案
```

全部进入 `field_candidates`。

9.8 P2: Forum Review

新增目录：

```
webapp/research_agents/forum/  
  moderator.py  
  claim_card.py  
  conflict_detector.py  
  refetch_planner.py
```

最小功能：

1. 检查同一字段多候选值是否冲突；
2. 检查 confirmed 字段是否有 evidence；
3. 检查市场字段是否有口径；
4. 生成补采任务；
5. 输出人工确认清单。

10. 推荐目录结构

```
webapp/research_agents/  
  __init__.py  
  orchestrator.py  
  state.py  
  contracts.py  
  
  agents/  
    identity_agent.py  
    source_planning_agent.py  
    official_agent.py  
    query_agent.py  
    github_agent.py  
    media_agent.py  
    community_agent.py  
    insight_agent.py  
    metric_agent.py  
    competitor_agent.py  
    report_agent.py  
  
  forum/  
    moderator.py  
    claim_card.py  
    conflict_detector.py  
    refetch_planner.py  
  
  resolvers/  
    field_resolver_v2.py  
    metric_resolver.py  
    market_size_resolver.py  
    competitor_resolver.py  
    gtm_resolver.py
```

```
storage/  
  document_store.py  
  evidence_store.py  
  candidate_store.py
```

不建议现在重写前端。

先保持前端继续读取 `research_fields / final_fields`，后端新增兼容层。

11. 字段配置文件设计

扩展 `references/field_manifest.yaml`。

示例：

```
funding_info:  
  category: A  
  resolution_type: official_fact  
  required_evidence: true  
  allowed_sources:  
    - official_press  
    - trusted_media  
    - financial_database  
  refetchable: true  
  card_no: 2  
  
market_cagr:  
  category: C  
  resolution_type: market_model  
  required_context:  
    - region  
    - segment  
    - year  
  allow_proxy: true  
  refetchable: true  
  card_no: 2  
  
ltv_cac_ratio:  
  category: D  
  resolution_type: private_metric  
  required_evidence: true  
  fallback:  
    - industry_avg  
  refetchable: false  
  card_no: 6  
  
active_users:  
  category: E  
  resolution_type: b2b_remap
```

```
b2b_replace:
- paying_customers
- customer_logos
refetchable: false
card_no: 3
```

12. 实施计划

阶段 1：稳定现有链路

目标：修复最关键的数据污染问题。

任务：

1. 修复 `_prepare_raw_data_for_llm()`，保留 `evidence_pool`。
2. `field_resolver.py` 增加 `llm_extracted / industry_avg / conflict`。
3. `gap_detector.py` 读取 `field_manifest.yaml`。
4. `research_fields / final_fields` 增加 `company_key`。
5. final 字段定稿时保留 `source_evidence_ids`。

验收：

任意公司研究结果中：

- 每个 `confirmed` 字段都有 `evidence`；
- 私有指标不会被反复补采；
- `Limitless / limitless` 不再分裂；
- L0 输入中能看到 `evidence_pool`。

阶段 2：证据层升级

目标：字段可追溯。

任务：

1. 新增 `source_documents`；
2. 新增 `evidence_spans`；
3. 采集结果先入 `source_documents`；
4. `EvidenceExtractor` 从文档中抽取字段证据；
5. `FieldResolver` 基于 `evidence_spans` 判断字段状态。

验收：

点击任一字段，可以看到：

- 来源 URL；
- 来源标题；
- 引用片段；

- 提取 Agent；
- 可信度；
- 是否存在冲突。

阶段 3：Agent 化采集

目标：从“搜索结果总结”升级为“字段驱动采集”。

任务：

1. 新增 OfficialAgent；
2. 新增 GitHubAgent；
3. 新增 MediaAgent 字幕提取；
4. 新增 CommunityAgent；
5. 新增 InsightAgent 行业均值；
6. SourcePlanningAgent 根据字段 manifest 生成任务。

验收：

同一个字段可以看到多个 Agent 的候选值。

阶段 4：Forum Review

目标：降低幻觉和冲突。

任务：

1. 新增 Claim Card；
2. 新增 ConflictDetector；
3. 新增 RefetchPlanner；
4. 新增人工确认清单；
5. 将冲突字段状态设为 conflict 或 manual_needed。

验收：

字段冲突不会直接进入 confirmed。

阶段 5：卡片配置化

目标：8 页卡片自由组合。

任务：

1. 新增 `card_schema`；

2. 新增 `final_card_values` ;
3. 前端定稿台读取 `card_schema`;
4. 卡片渲染不再绑定固定字段顺序;
5. 支持新增、隐藏、调序、换字段。

验收:

用户可以调整:

- 卡片数量;
- 每页字段;
- 字段顺序;
- 字段展示方式。

13. 优先级清单

P0 必做

1. 保留 `evidence_pool` 给 L0
2. `confirmed` 必须绑定 `evidence`
3. D/E 类字段禁止盲目补采
4. `company_key` 贯穿 `research_fields` / `final_fields`
5. LTV/CAC 使用三层降级规则

P1 应做

1. `source_documents`
2. `evidence_spans`
3. 官网深爬
4. `field_candidates`
5. `market_size_resolver`

P2 可做

1. `ForumModerator`
 2. `YouTube transcript`
 3. `CommunityAgent`
 4. `GitHub README` / `docs` / `issues` 深采
 5. 卡片 `schema` 配置化
-

14. 验收指标

14.1 采集质量指标

每家公司唯一 URL 数 ≥ 15
官网关键页抓取数 ≥ 5
confirmed 字段证据绑定率 $\geq 90\%$
市场字段口径完整率 $\geq 80\%$
私有指标误 confirmed 数 = 0

14.2 研究质量指标

字段缺失率下降
冲突字段被拦截
不可得字段有明确原因
LTV/CAC 不再伪装为公司事实
Top3 竞品有来源与差异说明
客户选择理由有证据支撑

14.3 产品质量指标

8 页卡片字段完整率 $\geq 85\%$
人工定稿时间下降 50%
同一公司重复研究可复用历史证据
字段修改不影响渲染层
新增字段不需要改核心 pipeline

15. 风险与约束

15.1 不要过早重写前端

当前最重要的是研究后端和数据库分层。
前端可以继续兼容旧表。

15.2 不要把所有字段都追求 confirmed

公开互联网无法稳定获得：

CAC
LTV
毛利率

Burn Rate
Runway
真实留存率

这些字段应接受：

unavailable
proxy
industry_avg
manual_needed

15.3 不要让卡片结构决定数据库

卡片页会变，数据库事实不应跟着变。
正确方式是：

数据库存事实
card_schema 决定如何展示

15.4 不要把 BettaFish 照搬过来

BettaFish 是舆情分析框架。
GZHv2 应借鉴：

多 Agent 分工
论坛式校验
公私域数据融合
模块化架构

不应照搬：

微博/小红书/抖音舆情爬虫
舆情情绪分析流程
大众评论处理逻辑

16. 最终形态

GZHv2 的最终架构应是：

研究台：

负责采集、证据、字段、分析、冲突处理

定稿台：

负责字段选择、文案压缩、状态确认、卡片组合

资产台：

负责 logo、截图、地图、竞品 logo、时间线、增长飞轮

渲染台：

负责 HTML / PNG / Markdown 输出

一句话目标：

把 GZHv2 从“能生成卡片的 LLM 工具”，升级成“字段可追溯、结果可复用、卡片可配置的 AI 初创公司商业研究中台”。