

SPEC：套卡3商业研究流水线升级

0. 背景

当前项目已经具备基础研究链路、证据表、字段表、卡片 schema、上下文压缩模块，但仍存在四类结构性问题：

1. 字段契约不完整，套卡3字段与数据库、manifest、prompt 未完全统一。
2. 噪音治理已有雏形，但 confirmed 字段没有强制证据绑定。
3. 上下文压缩已有模块，但字段级 token 预算和证据选择规则不够硬。
4. 研究链路仍偏“搜索驱动”，导致搜索过宽、私有指标补采浪费时间。

本次升级目标是把研究链路改为：

字段契约驱动 → 数据源分层采集 → 证据抽取 → 字段解析 → 覆盖率闸门 → 卡片生成

核心判断：

数据完整度不等于所有字段都有确定数值，而是所有字段都有可信状态。
私有指标不可得时，应输出 `unavailable / industry_avg / proxy`，不能诱导 LLM 编造。

1. 目标

1.1 功能目标

套卡3必须支持 8 页内容：

1. 首页：公司名称、公司分类。
2. 公司简介：赛道市场格局、赛道市场规模、CAGR、TAM、公司地理位置、成立时间、主营业务、核心竞争优势、融资情况、取得成就、行业定位。
3. 主产品：名称、痛点、核心功能、核心用法、技术栈、地区市场、MAU、留存率、定价明细。
4. 创始团队：创始人名称、经历、毕业院校、团队规模、团队亮点。
5. 用户群体：用户画像、客户名称、客户选择理由。
6. 公司能力分析：生态位分析、变现能力、LTV/CAC。
7. 增长与 GTM：GTM 策略、增长策略、增长飞轮。
8. 竞争态势：Top3 竞品简介、竞争位置、错位竞争机会、竞争优势。

1.2 质量目标

coverage_score >= 0.95
confirmed 字段 100% 绑定 evidence_span
P95 run_time <= 900s
L0 context <= 18000 tokens
私有指标无披露时 0 次强行编造

1.3 非目标

本次不追求：

- 1. 100% 字段都有确定数值。
- 2. 100% 自动抓到私有公司 MAU、留存率、LTV、CAC。
- 3. 引入复杂多 Agent 辩论作为默认热路径。
- 4. 图片采集进入 15 分钟 SLA。

2. 核心术语

2.1 Field Manifest

字段清单。定义每个字段的来源、类型、是否必填、是否可补采、是否私有、默认回退策略。

2.2 Evidence Span

证据片段。字段不能直接来自 LLM 总结，必须尽量绑定原始网页、新闻、报告、API 返回中的具体片段。

2.3 Coverage Score

字段完整度分数。不是简单空值率，而是按字段状态计算。

2.4 P95

第 95 百分位耗时。意思是 95% 的研究任务都应在 900 秒以内完成。

3. 字段状态模型

所有最终字段必须有 `resolution_status`。

<code>confirmed</code>	有可信来源和 <code>evidence_span</code>
<code>derived</code>	由 <code>confirmed</code> 字段计算得到
<code>proxy</code>	使用代理指标，已说明口径
<code>industry_avg</code>	使用行业均值，已说明非公司披露
<code>unavailable</code>	私有指标不可得
<code>not_applicable</code>	对该公司不适用
<code>manual_needed</code>	自动链路不足，需要人工确认
<code>llm_extracted</code>	LLM 抽取但证据不足

状态得分：

```
confirmed: 1.0
derived: 1.0
unavailable: 1.0
not_applicable: 1.0
```

```
proxy: 0.8
industry_avg: 0.8
manual_needed: 0.6
llm_extracted: 0.5
empty: 0
```

coverage 计算：

$$\text{coverage_score} = \frac{\sum(\text{field_weight} \times \text{status_score})}{\sum(\text{field_weight})}$$

硬规则：

confirmed 字段必须满足：

1. evidence_span_ids 非空
2. source_score ≥ 0.65
3. entity_score ≥ 0.60
4. evidence_strength $\neq \text{weak}$

4. 字段可得性分级

A 类：高可得字段

通常能从官网、LinkedIn、新闻、数据库获得。

```
company_name
company_type
location
founded_year
business_summary
main_product_name
core_features
pricing
founder_names
founder_experience
funding_rounds
competitors
```

策略：必须优先达到 `confirmed`。

B 类：中可得字段

需要多源交叉验证。

```
market_size
market_cagr
tam
market_landscape
industry_position
core_competitive_advantage
customer_profiles
gtm_strategy
growth_strategy
```

策略：允许 `confirmed` / `proxy` / `manual_needed`。

C 类：推理型字段

需要基于证据综合判断。

```
ecosystem_position
monetization_ability
growth_flywheel
competitive_position
differentiated_opportunity
competitive_advantage
```

策略：可以由 LLM 生成，但必须引用输入 `evidence_spans`。

D 类：私有指标

私有公司通常不可得。

```
mau
retention_rate
ltv
cac
```

策略：

```
有公司披露 → confirmed
有第三方合理估算 → proxy
无披露 → unavailable
行业可比数据可得 → industry_avg
禁止初始补采宽搜
```

5. 数据库修改

5.1 统一字段命名

保留以下命名：

```
company_type  
funding_rounds  
product_tech_stack  
gtm_strategy  
differentiated_opportunity
```

废弃或映射：

```
company_category -> company_type  
funding_info -> funding_rounds_summary  
tech_stack -> product_tech_stack  
gtm_motion -> gtm_strategy  
differentiation_strategy -> differentiated_opportunity
```

5.2 实体表主写入

研究事实优先写入实体表：

```
companies  
products  
metrics  
sectors  
founders  
funding_rounds  
customers  
competitors  
company_analysis
```

`final_card_values` 只作为卡片展示读模型。

5.3 所有实体表增加审计字段

每个实体表增加：

```
evidence_span_ids TEXT;  
resolution_status TEXT NOT NULL DEFAULT 'manual_needed';  
confidence REAL DEFAULT 0.0;  
as_of_date TEXT;  
source_note TEXT;
```

5.4 final_card_values 增强

增加字段：

```
field_key TEXT NOT NULL;  
field_value TEXT;  
resolution_status TEXT NOT NULL;  
confidence REAL DEFAULT 0.0;  
evidence_span_ids TEXT;  
source_note TEXT;  
card_id TEXT;  
updated_at TEXT;
```

唯一约束：

```
UNIQUE(company_id, card_id, field_key)
```

6. Field Manifest 规范

新增或补全：

```
card3:  
  company_name:  
    page: 1  
    required: true  
    availability_class: A  
    source_priority: [official_site, linkedin, crunchbase, tavily]  
    confirm_required: true  
    fallback: manual_needed  
  
  company_type:  
    page: 1  
    required: true  
    availability_class: A  
    source_priority: [official_site, linkedin, tavily]  
    confirm_required: true  
    fallback: llm_extracted  
  
  market_landscape:  
    page: 2  
    required: true  
    availability_class: B  
    source_priority: [industry_report, sec, cbinsights, gartner, tavily]  
    confirm_required: false  
    fallback: proxy
```

market_size:
page: 2
required: true
availability_class: B
unit_required: true
region_required: true
year_required: true
fallback: proxy

market_cagr:
page: 2
required: true
availability_class: B
unit_required: true
period_required: true
fallback: proxy

tam:
page: 2
required: true
availability_class: B
unit_required: true
region_required: true
year_required: true
fallback: proxy

mau:
page: 3
required: true
availability_class: D
private_metric: true
source_priority: [company_disclosure, similarweb, app_store, tavily]
fallback: unavailable

retention_rate:
page: 3
required: true
availability_class: D
private_metric: true
fallback: unavailable

ltv_cac:
page: 6
required: true
availability_class: D
private_metric: true
source_priority: [company_disclosure, sec, industry_benchmark]
fallback: industry_avg

要求:

1. card_schema 中所有字段必须存在于 field_manifest。
2. field_manifest 中不得存在未被 card_schema 使用的孤儿字段，除非标记 internal_only。
3. D 类字段不得进入初始 search query。

7. 研究主链路

7.1 新链路

```
Input
↓
IdentityResolver
↓
CardSchemaLoader
↓
FieldManifestLoader
↓
FieldDrivenSourcePlanner
↓
Parallel SourceAdapters
↓
SourceDocuments
↓
DocumentCleaner
↓
DocumentChunker
↓
EvidenceRanker
↓
EvidenceSpanExtractor
↓
ContextPacker
↓
FieldCandidateResolver
↓
CoverageGate
↓
GapRefetch, 最多一次
↓
FinalCardValueWriter
```

7.2 IdentityResolver

输入：

```
{
  "company_name": "Limitless",
```

```
"website": "https://www.limitless.ai"
}
```

输出：

```
{
  "company_key": "limitless_ai",
  "canonical_name": "Limitless",
  "aliases": ["Limitless AI", "Limitless.ai"],
  "official_domain": "limitless.ai",
  "country_hint": "US"
}
```

作用：

1. 避免 limitless / Limitless 混淆。
2. 给 evidence_ranker 提供 entity_score。
3. 给 source planner 限定查询。

8. SourceAdapter 规范

统一接口：

```
class SourceAdapter:
    source_family: str
    timeout_seconds: int
    max_documents: int

    def collect(
        self,
        company_identity: dict,
        field_targets: list[dict],
        budget: dict
    ) -> list[SourceDocument]:
        ...
```

SourceDocument 必须包含：

```
{
  "url": "...",
  "title": "...",
  "source_family": "official_site",
  "source_score": 0.9,
  "published_at": "2026-01-01",
}
```

```
"raw_text": "...",  
"metadata": {}  
}
```

8.1 默认 Adapter

```
OfficialSiteAdapter  
TavilySearchAdapter  
TavilyExtractAdapter  
GitHubAdapter  
ProductHuntAdapter  
YouTubeTranscriptAdapter  
SECAAdapter  
OpenBBAdapter  
CompaniesHouseAdapter  
BuiltWithAdapter
```

8.2 默认采集预算

```
official_site: 5 urls  
search: 14 queries max  
extract: 20 urls max  
github: 3 repos max  
producthunt: 3 posts max  
youtube: 3 videos max  
sec: 5 filings max  
benchmark: 5 docs max
```

9. 搜索计划规则

9.1 初始搜索只覆盖 A/B/C 类字段

禁止初始 query 包含：

```
MAU  
retention rate  
LTV  
CAC  
monthly active users  
customer acquisition cost
```

除非公司为上市公司或已有披露线索。

9.2 Query 生成模板

```
{company} official site
{company} pricing
{company} founder
{company} funding
{company} customers case study
{company} competitors
{company} product demo
{company} product hunt
{company} market size {sector}
{company} alternative
```

9.3 Gap Refetch

只允许一次。

触发条件：

```
coverage_score < 0.95
或 required A 类字段为空
或 confirmed 字段比例 < 0.65
```

Gap query 最多 4 条。

10. 噪音治理

10.1 DocumentCleaner 规则

直接删除：

```
cookie banner
privacy policy
terms of service
footer
navigation
login page
newsletter popup
广告弹窗
重复菜单
```

降权：

```
招聘页
纯营销口号页
```

社区评论
无日期转载页
聚合站
低质量 SEO 站

10.2 Chunk 规则

chunk_size: 900-1200 chars
chunk_overlap: 120 chars
min_chunk_chars: 120
每 URL 最多保留 3 个高分 chunk
每 source_family 最多保留 12 个 chunk

10.3 Evidence Ranking

评分公式：

```
final_score =  
0.30 * source_score  
+ 0.20 * entity_score  
+ 0.25 * field_relevance  
+ 0.10 * freshness  
+ 0.15 * info_density  
- 0.30 * noise_score
```

硬过滤：

entity_score < 0.35 且非行业报告 → 丢弃
noise_score > 0.75 → 丢弃
重复 chunk similarity > 0.88 → 只保留最高分

11. 上下文压缩

11.1 L0 Context Budget

```
max_tokens: 18000  
company_identity: 600  
source_audit: 1000  
market_context: 2200  
product_context: 2200  
founder_context: 1600  
customer_context: 1800  
gtm_context: 2200
```

```
competition_context: 3000
misc_buffer: 3400
```

11.2 输入 LLM 的内容

禁止输入 raw full text。

只允许：

```
{
  "company_identity": {},
  "field_targets": [],
  "source_audit": [],
  "evidence_spans": [],
  "packed_context": []
}
```

11.3 字段级证据限制

```
每字段 Top 3 evidence_spans
每字段 Top 5 chunks
每字段最多 2200 tokens
竞争态势最多 3000 tokens
```

12. 字段解析规则

12.1 FieldCandidate

每个字段生成候选：

```
{
  "field_key": "pricing",
  "value": "$20/month Pro plan",
  "resolution_status": "confirmed",
  "confidence": 0.86,
  "evidence_span_ids": ["span_123"],
  "source_note": "Official pricing page, accessed 2026-06-17"
}
```

12.2 冲突处理

优先级：

官方披露 > SEC/监管文件 > 投资人/融资新闻 > 权威媒体 > 第三方数据库 > 社区评论 > LLM 推断

同类来源冲突：

1. 选择更新日期更近者。
2. 若口径不同，保留多个值并标注口径。
3. 不允许无解释覆盖。

13. 卡片生成规则

13.1 第1页

字段：

company_name
company_type

最低要求：

company_name: confirmed
company_type: confirmed 或 llm_extracted

13.2 第2页：公司简介

字段：

market_landscape
market_size
market_cagr
tam
location
founded_year
business_summary
core_competitive_advantage
funding_rounds
achievements
industry_position

要求：

市场字段必须带 region/year/source。
融资字段必须带 round/date/investor/amount，缺失项标注 unknown。

13.3 第3页：主产品

字段：

main_product_name
pain_points
core_features
core_usage
product_tech_stack
regional_market
mau
retention_rate
pricing_details

要求：

mau 和 retention_rate 无披露时输出 unavailable。
不能使用“可能”“预计”生成假数值。

13.4 第4页：创始团队

字段：

founder_names
founder_experience
founder_education
team_size
team_highlights

要求：

创始人教育经历必须有来源，否则 manual_needed。

13.5 第5页：用户群体

字段：

user_profiles
customer_names
customer_selection_reasons

要求：

客户名称必须来自官网客户页、case study、新闻或可信数据库。
客户选择理由必须绑定事实，例如部署场景、效率提升、成本下降、集成能力。

13.6 第6页：公司能力分析

字段：

ecosystem_position
monetization_ability
pricing_strategy
ltv_cac

要求：

LTV/CAC 无公司披露时使用 industry_avg 或 unavailable。
必须显式说明“非公司披露”。

13.7 第7页：增长与 GTM

字段：

gtm_strategy
growth_strategy
growth_flywheel

要求：

增长飞轮可以由 LLM 综合，但输入必须来自 evidence_spans。

13.8 第8页：竞争态势

字段：

top3_competitors
competitor_summaries
competitive_position
differentiated_opportunity
competitive_advantage

要求：

Top3 竞品必须有：

1. 名称
2. 简介
3. 与被研公司的重叠点
4. 与被研公司的差异点

14. 覆盖率闸门

CoverageGate 输出：

```
{
  "coverage_score": 0.96,
  "confirmed_ratio": 0.71,
  "missing_required_fields": [],
  "weak_fields": ["founder_education"],
  "private_metric_fields": {
    "mau": "unavailable",
    "retention_rate": "unavailable",
    "ltv_cac": "industry_avg"
  },
  "should_refetch": false
}
```

触发失败：

```
coverage_score < 0.95
A 类 required 字段为空
confirmed 字段无 evidence_span
L0 tokens > 18000
runtime > 900s
```

15. 环境变量

推荐默认值：

```
RESEARCH_DEPTH=standard
TAVILY_ADAPTIVE_MODE=1
TAVILY_INITIAL_QUERY_LIMIT=8
TAVILY_QUERY_BUDGET_STANDARD=14
TAVILY_QUERY_BUDGET_DEEP=18
TAVILY_RESULTS_PER_QUERY=5
COLLECTION_GAP_QUERY_LIMIT=4
COLLECTION_ENABLE_GAP_REFETCH=1
```

```
ORCHESTRATOR_ENABLED=0
FORUM_MODERATOR_ENABLED=1
AGENT_DEBATE_ENABLED=0

LO_CONTEXT_BUDGET_TOKENS=18000
RAW_TEXT_IN_LLM_ENABLED=0
POSTHOC_EVIDENCE_WEAK_ONLY=1

MAX_CHUNKS_PER_URL=3
MAX_CHUNKS_PER_SOURCE_FAMILY=12
MAX_EVIDENCE_SPANS_PER_FIELD=3

CARD_SCHEMA_VERSION=v3
FIELD_MANIFEST_REQUIRED=1
```

16. 测试用例

16.1 字段契约测试

输入：

```
card_schema v3
field_manifest.yaml
fields.json
```

预期：

1. card_schema 所有字段都存在于 field_manifest。
2. fields.json 与 manifest 字段别名一致。
3. 不存在 company_category/company_type 双写。

16.2 私有指标测试

输入：

```
私有 B2B SaaS 公司
```

预期：

```
mau: unavailable 或 proxy
retention_rate: unavailable
```

ltv_cac: industry_avg 或 unavailable
不得编造具体数值

16.3 证据绑定测试

输入:

融资字段由 LLM 抽出, 但无 evidence_span

预期:

resolution_status != confirmed

16.4 噪音测试

输入:

cookie banner / footer / terms / nav heavy 页面

预期:

不进入 packed_context

16.5 上下文预算测试

输入:

500 chunks

预期:

L0 context <= 18000 tokens
每 URL <= 3 chunks

16.6 市场字段测试

输入:

market_size 无 region/year/source

预期:

不得 confirmed
只能 proxy 或 manual_needed

16.7 客户字段测试

输入：

客户名来自官网 customer page

预期：

customer_names confirmed
customer_selection_reasons 至少绑定一个事实证据

16.8 竞品字段测试

输入：

Top3 competitors

预期：

每个竞品都有：
name
summary
overlap
difference

16.9 15分钟 SLA 测试

Anchor companies：

Anthropic
Perplexity
Cursor
Lovable
ElevenLabs
Runway
Glean
Limitless

预期：

```
P95 runtime <= 900s
coverage_score >= 0.95
```

17. 实施顺序

P0: 字段契约和质量闸门

1. 补全 `field_manifest.yaml`。
2. 统一字段名。
3. 增加字段状态模型。
4. `confirmed` 字段强制 `evidence_span`。
5. D 类字段移出初始搜索计划。
6. CoverageGate 加入测试。

验收:

```
字段契约测试通过
私有指标测试通过
证据绑定测试通过
```

P1: 字段驱动采集

1. 新增 `FieldDrivenSourcePlanner`。
2. 新增 `SourceAdapter` 基类。
3. 改造 Tavily/Official/GitHub/ProductHunt/SEC 为 adapter。
4. SourceDocuments 统一入库。
5. GapRefetch 限制为最多一次。

验收:

```
搜索 query 数下降
coverage 不下降
runtime 下降
```

P2: 上下文预算硬化

1. ContextPacker 改成字段级预算。
2. LLM 输入禁止 raw full text。
3. 每字段限制 Top evidence。
4. 加入 L0 token 测试。

验收:

```
L0 context <= 18000 tokens
无上下文爆炸
```

P3: 实体表主写入

1. companies/products/metrics 等实体表成为主写入。
2. final_card_values 由实体表生成。
3. 宽表只保留兼容。
4. 每条实体记录带 evidence/status/confidence。

验收:

卡片字段可回溯
旧卡片不回归

18. 验收标准

最终必须满足:

1. 套卡3 8 页字段全部可生成。
2. coverage_score ≥ 0.95 。
3. confirmed 字段 100% 有 evidence_span。
4. D 类私有指标无披露时不编造。
5. P95 runtime $\leq 900s$ 。
6. L0 context ≤ 18000 tokens。
7. 每 URL 最多 3 chunks。
8. 每公司最多 1 次 gap refetch。
9. 字段别名无冲突。
10. v1/v2 老卡片不回归。

19. 关键设计取舍

19.1 不默认启用复杂多 Agent

原因:

多 Agent 会提高成本、耗时和上下文不确定性。
当前瓶颈不是“观点不够多”，而是字段契约和证据绑定不够硬。

处理:

ForumModerator 保留为审计模块。
默认热路径不进入多 Agent 循环。

19.2 私有指标不强求数值

原因：

MAU、留存率、LTV、CAC 对私有公司通常不可得。
强行补采只会增加时间和幻觉。

处理：

用 unavailable / proxy / industry_avg 替代空值。

19.3 以实体表为主，而不是继续扩宽表

原因：

套卡字段会继续变化。
宽表会导致字段膨胀、迁移困难、证据不可追溯。

处理：

实体表写事实。
final_card_values 写展示。

20. 给实现者的最终指令

实现时优先级如下：

正确性 > 可追溯 > 15分钟 SLA > 字段丰富度 > Agent 复杂度

不要通过增加搜索量解决质量问题。

先通过字段契约、证据绑定、上下文预算、状态模型解决质量问题。

本次升级完成后，项目应从“LLM 辅助生成卡片”升级为：

可审计的商业研究数据管线 + 卡片生成系统